

李昊伟

☎ 13283542497 ✉ 906782061@qq.com 📍 北京
🎂 29岁 🧑 男 🏠 汉族
👤 大模型算法工程师

教育经历

太原理工大学 211 2015年09月 - 2019年07月
软件工程 本科 大数据学院 全日制 太原
【GPA】3.99/5.0
【奖学金】获得专业学习类奖学金（2016-2018）

专业技能

1. 编程语言：Python，C++，Java
2. 大模型 / NLP：Transformer，BERT，GPT，RAG，Agent，ReAct，对话管理，意图识别，槽位抽取，文本分类，关键词抽取
3. 模型训练与优化：PyTorch，HuggingFace Transformers，PEFT，LoRA，P-tuning，模型量化，推理加速
4. Agent 与应用框架：LangChain，Dify，MCP，Docling，FastGPT 类知识库 / Agent 平台设计
5. 检索与知识工程：Elasticsearch，Neo4j，HanLP，知识图谱，图检索，PageRank，TextCNN
6. 工程化与部署：Django，ONNX，TVM，MLC-LLM，端云协同，模型下发与同步，权限控制，多租户架构

工作经历

北京康吉森技术有限公司 2025年06月 - 至今
AI应用工程师 AI业务发展部 北京
核心贡献: 作为集团内唯一 AI 算法角色，负责集团 AI 智能化架构设计与核心应用落地，独立推进企业智能体、工业智能诊断、工业装置智能操作指导与内部知识库平台建设，覆盖需求拆解、算法建模、系统设计、工程实现与业务交付。、

【工业装置智能操作指导】
面向云南石化气体分馏装置，构建基于实时组态状态的两阶段操作建议模型，为操作员判断当前是否需要操作，并在需要操作时推荐候选 SV 位号及调节方向。项目针对工业数据样本少、工况长期平稳、动作稀疏、操作模式随时间漂移等问题，采用“Gate 触发判断 + Ranker 候选操作排序”的建模路线。

1. 基于工艺流程知识与组态拓扑按装置梳理关键 PV / SV 位号，构建 PV 状态与趋势特征、SV 当前设定与历史调节特征、全局操作上下文特征。
2. 构建 Gate 模型判断当前组态状态下是否需要触发操作建议，基于分钟级时间点构造正负样本，将真实动作包发生时刻作为正样本，非操作时刻作为负样本。
3. 使用 Gate 先过滤大量无需操作的平稳时刻，缓解动作稀疏导致的误报问题；Gate 触发后再进入 Ranker，对候选 SV + direction 进行打分排序。
4. 针对工况极端平稳、短期 PV / SV 变化弱的问题，重点利用单一历史窗口内的平滑状态、区间趋势、历史 SV 调节和全局操作上下文刻画当前操作意图。
5. 使用 CatBoost / XGBoost 类树模型分别构建 Gate 与候选操作 Ranker，其中 Ranker 将每个候选操作建模为二分类打分问题，并按分数排序输出操作建议列表。
6. 使用 AUC、precision、recall 评估 Gate 触发效果，使用 hit@1，positive recall@k、event recall 等指标评估 Ranker 推荐效果，并对时间切分与随机切分下的操作模式漂移进行误差分析。阶段性离线实验中，候选操作 Top-3 覆盖率达到约 91%。

【集团内部业务智能体】
面向财务、法务、质量等内部业务场景，设计并落地财务智能体、合同审核智能体、模板文书合规性检测智能体等应用。

1. 将财务、合同审核、质量文书检查等重复性业务封装为可复用 Agent / Skill，降低人工处理成本。
2. 在合同积压场景下支持自动生成审核报告，缓解法务审核压力。
3. 对格式类、模板类文书进行自动合规检测，替代部分人工初筛工作。

【设备故障智能诊断】
基于公司产品历史故障记录，设计面向设备故障报警的智能诊断系统。

1. 构建基于图检索的领域知识库，将历史故障、报警现象、处理动作与设备结构进行关联建模。
2. 面向设备报警自动生成故障原因分析与处理建议，提高故障处理知识复用效率。

【集团内部知识库与通用智能体入口】

早期设计并实现企业级 Agent 构建平台雏形，后续收敛为集团内部知识库与通用智能体入口。

1. 设计类似 FastGPT 的企业级 Agent / 知识库平台，支持知识库维护、权限控制、多租户隔离与内部智能体统一入口。
2. 使用 Docling 解析多格式文档，并支持文档图片转描述后参与检索，提升非结构化资料可检索性。
3. 将财务、合同、质量等业务能力封装为平台 Skill，实现内部智能体能力复用。

中科星图维天信科技股份有限公司

2025年03月 - 2025年06月

AI算法工程师 研究院

北京

【气象智能体】

基于多模态大模型、MCP 与 Dify Workflow 构建面向多场景的气象智能体。

1. 使用 MCP 驱动 Dify 工作流，实现气象数据查询、分析、生成与工具调用的自动化编排。
2. 改进 ReAct 执行流程，使任务执行过程支持中断与人工介入，增强复杂任务执行的可控性。

【多任务执行调度框架】

基于 LangChain 设计可自动规划、执行与修正的函数 / 算子调度框架。

1. 构建自动生成 Plan 并在执行过程中动态修正 Plan 的任务调度机制。
2. 支持根据任务状态选择可靠工具，并在执行偏离目标时根据下一步反馈调整执行路径。

鼎道智联（北京）科技有限公司

2023年06月 - 2025年03月

ai算法工程师 数字化运营，大模型与与算法研发

北京

【面向操作系统服务调度的多任务 Agent】

参与研发面向操作系统本地服务调度的多任务、多依赖、可扩展 Agent，负责对话管理与任务状态控制模块。该项目在 MCP / Skill 生态成熟前，通过服务选择、动态状态机与对话栈机制，实现用户自然语言指令到本地系统服务的调度执行。

1. 基于有限状态机构建早期对话管理策略，支持槽位缺失追问、任务状态维护与单任务执行。
2. 引入大模型能力，使系统支持多任务、多上下文切换，并能够围绕用户当前关注任务进行槽位填充。
3. 设计任务依赖识别机制，识别多个任务之间的槽位依赖关系，并按依赖顺序连续执行多个系统服务。
4. 不预先维护所有任务状态机，而是基于服务选择模块返回的服务定义即时构造任务状态机，降低新增任务类型时的改造成本。
5. 使用对话栈维护多个同类任务状态机，支持多任务并行对话与上下文切换，降低对话管理模块复杂度。
6. 支持用户自定义意图、任务触发指令与槽位填充示例，并结合 RAG 提升任务识别与槽位泛化能力。

【大模型端侧场景优化】

基于 TVM 上的 MLC-LLM 源码改造，完成对话系统相关模型在端侧设备上的部署与推理优化。

修改 MLC-LLM 推理框架，在模型前向计算中注入 LoRA 参数，使非 CUDA 场景下支持一个基座 LLM 搭配多个 LoRA 权重推理。为整套对话系统的本地化部署提供模型推理基础能力。

【模型引擎工程化开发】

参与统一模型引擎建设，支持小模型、大模型与 ONNX 模型的统一推理接口。

1. 实现模型下发、同步与端云协同机制，保障终端始终使用最新模型版本。
2. 统一不同模型格式与推理方式，降低业务侧接入成本。

同方知网数字出版技术有限公司

2021年04月 - 2023年06月

python研发-NLP方向 大数据资源部

太原

【知网产业创新生态系统】

负责产业分类、文献 / 专利 / 企业数据匹配与检索性能优化。

1. 针对早期依赖人工编写复杂检索式、维护成本高、查询速度慢的问题，基于 Elasticsearch 重新设计数据存储范式。
2. 将分类树路径信息写入文献与企业条目，支持基于节点名称直接查询，简化检索流程。
3. 在无 GPU、长文本、需快速迭代的约束下，使用 TextCNN 替代人工检索式进行类别分配，准确率达到 92%，F1 达到 88%。
4. 将系统响应速度从秒级优化至毫秒级。

【基础工具研发与词表数据精细化】

负责大规模 NLP 基础工具与领域词表清洗建设。

1. 开发基于 Spark + HanLP 的大规模分布式分词器、TextRank 抽取器与 Elasticsearch 分词插件。
2. 汇集知网多库机标关键词、人工关键词、领域词汇与开源词表，结合规则与 HanLP 序列化异常信息进行清洗。
5. 将词表规模由 1500 万清洗至 900 万，并支持分词器加载该规模词表。
6. 在知网关键词检索场景下，将首屏命中表现由 0.65 提升至 0.85。

其他

- 语言：英语（CET-6）



超级简历

该简历由超级简历提供制作支持

www.wondercv.com

Forgelet & SkillFS | 个人 Agent Infra 架构项目 | 设计与原型探索中

围绕 AI Agent 长任务执行、持久化运行环境、工具调用、技能规模化管理与上下文压缩问题，设计个人 Agent 基础设施方案。项目当前处于架构设计与原型探索阶段，主要用于沉淀 Agent Infra 方向的系统设计、模块边界与工程实现方案。SkillFS 已经完成 1.0 功能即将上线

【Forgelet：持久化 Agent Runtime】

Forgelet 面向长任务与复杂工程任务场景，探索将 Agent 与独立运行环境强绑定，而不是将 Agent 仅视为一次性对话或无状态 Workflow。

1. 设计 Agent 与 Runtime 强绑定模型：每个 Agent 拥有独立运行环境、文件系统工作区和长期状态，支持跨会话延续任务上下文。
2. 设计最小化内置工具集：以文件读取、文件写入、Shell 执行为基础能力，其他外部能力通过 MCP / Tool 接入，降低运行时核心复杂度。
3. 规划基于 Incus 的隔离运行环境，支持独立系统盘 / 工作区、快照、克隆与人工 checkpoint，用于高风险操作前回滚与恢复。
4. 将人工 checkpoint 作为核心交互机制，避免完全自动化恢复带来的不可控性，使用户能够在关键节点确认、保存或回退运行时状态。
5. 围绕 Agent、Runtime、Tool、Memory 等模块拆分边界，沉淀核心数据结构、接口设计与实现任务文档。

【SkillFS：云端 Retrieval-first Skill 文件系统】

SkillFS 面向大规模 Skill 管理问题，目标是将 Skill 以云端、可检索、按需加载的方式暴露给 Agent，避免大规模 Skill 目录直接进入上下文造成 prompt 膨胀。

1. 设计 retrieval-first 的 Skill 管理方式：Agent 先根据任务搜索相关 Skill，再按需加载 Skill 内容，而不是预先安装或注入完整 Skill 列表。
2. 将 Skill 抽象为云端文件系统式资源，规划通过类文件系统接口暴露 Skill 的目录、元信息、内容与版本，降低不同 Agent 工具接入成本。
3. 规划 SkillFS 拆分为 Cloud API、Website UI、Local Components 三部分，分别负责云端索引检索、技能管理界面与本地工具适配。

考虑兼容 Claude Code / Cursor / Codex 等 AI Coding 工具的技能目录与使用方式，使 Skill 能在不同工具和 Agent Runtime 中复用。

针对 10,000+ Skill 场景，设计“搜索 + 懒加载”的上下文控制策略，将 Skill 管理从 prompt 枚举问题转化为检索与加载问题。

4. 在文件系统式抽象下管理 Skill 的查询、读取与加载状态，使多 Agent 并发查询时能够通过统一命名空间、只读 Skill 内容与独立加载上下文减少冲突，避免不同 Agent 之间的 Skill 状态污染。
5. 设计 SkillFS 本地缓存机制，对高频访问 Skill、索引摘要与元信息进行分层缓存，减少重复远程检索与加载开销。
6. 设计 SkillFS 缓存 GC 机制，基于访问时间、引用状态、版本有效性与容量阈值清理过期 Skill 缓存，避免长期运行后本地缓存膨胀。

大型康养中心安防与办公高可用架构设计

独立统筹并落地含 110 路摄像头、260T 分布式大容量存储的监控与办公系统架构。

1. 负责整体硬件选型、网络拓扑设计及高可用集群部署。
2. 在成本控制、系统稳定性与可维护性之间进行架构权衡，实现监控、办公与存储系统的稳定运行。

