

个人简历

PERSONAL RESUME

个人信息

Personal information

姓名：马浩宇

籍贯：安徽省宣城市

年龄：26

毕业院校：东北大学

手机号码：13364493451

邮箱：aidev_hy@163.com

教育背景

Educational background

2018.09-2022.06

东北大学 | 985 | 双一流

信息安全

专业技能

Professional skills

- 熟悉MCP协议和Langgraph框架，掌握Agent智能体构建技术
- 熟悉Langchain开发工具，掌握LLM, PromptTemplates, OutputParser, Chains等组件的使用
- 熟悉大模型的微调：SFT、RLHF/DPO、LoRA/QLoRA等技术，熟悉大模型的模型压缩算法
- 熟悉Transformer、BERT、LSTM等深度学习模型原理，并能够结合实际业务加以运用
- 熟悉DeepSeek、Qwen、Llama、GPT、GLM等主流大模型
- 处理传统NLP实践任务：情感分析、文本翻译、文本分类、信息抽取、知识图谱等
- 理解主流机器学习算法：线性回归、逻辑回归、K-Means、决策树、XGBoost等算法原理。
- 熟悉Python语言，具备良好编程规范，熟练使用pytorch框架
- 掌握MySQL, Neo4j, milvus等数据库的使用，常规Linux系统操作

工作经历

Work experience

2024.01-2026.06

大模型算法工程师

安徽思高智能科技有限公司

2022.07-2023.12

NLP算法工程师

上海科之锐人才咨询有限公司

项目经历

Project experience

2025.12-2026.06

多Agent智能办公助手

项目背景：

为提升企业员工办公效率，聚焦知识问答，数据分析，流程自动化，日程与会议管理，内容生成场景，主导设计研发企业多智能体助手系统，项目基于 LangGraph 构建多 Agent 智能办公助手，实现意图识别，任务规划等功能，构建业务子图，实现企业办公场景下的自动化任务编排与跨系统协同。

技术栈：

Python、FastAPI、Uvicorn、Qwen、LangGraph、LangChain、Postgresql

项目职责：

1. 负责多 Agent 智能办公助手整体架构设计，基于LangGraph构建主图与业务子图，将系统拆分为意图识别、任务规划、结果聚合等核心节点，提升流程的可维护性和可扩展性。
2. 负责意图识别模块开发，使用大模型结构化输出能力识别用户输入中的单意图或多意图任务，并生成标准化执行计划，为后续任务分发和并行执行提供依据。
3. 设计实现长短期记忆机制，启用Checkpoint 持久化会话状态。从用户对话中提取信息再通过嵌入模型转化为向量存入向量数据库中实现长期记忆存储，并在更新记忆时实现语义去重机制。
4. 负责MCP工具调用层封装，将 workflow 发起等接口抽象为标准MCP工具，降低 Agent 与业务系统之间的耦合。
5. 负责高风险操作的人机确认机制设计，对请假提交、报销申请等操作增加 HITL 确认流程，确保用户确认后再调用MCP服务，避免误操作和重复提交。

项目成果：

1. 系统落地应用：成功开发并上线多Agent办公系统，覆盖公司所有部门，系统日均活跃率达60%以上，实现办公场景智能化覆盖；
2. 效率显著提升：员工知识检索时间平均缩短80%，会议预定耗时减少60%，日报周报等内容生成时间从平均30分钟缩短至3分钟以内；
3. 意图识别精准：提示词优化后的意图识别准确率达92%以上，覆盖知识问答、请假申请、会议室预定等高频办公场景，避免指令混淆，提升Agent交互体验；
4. 任务完成率达到88.6%，员工满意度达到90%+；
5. 成本节约：通过减少重复性工作、优化办公流程，达成项目提升员工办公效率、降低运营成本的核心目标。

2025.05-2025.11

基于RAG技术的知识问答系统

项目背景：

企业内部知识资产分散，包括员工手册、财务报销制度、开发规范、安全规范、产品技术文档等。此前员工获取内部知识主要依靠人工检索共享盘、咨询老员工或行政/技术部门，检索效率极低，平均查找一个问题答案需15分钟以上，新员工培训成本高，需花费1-2周熟悉各类内部知识，上手效率慢。为解决上述问题，提升企业内部协作效率、降低培训成本、规范知识传递，启动企业内部知识问答系统项目，基于RAG架构搭建智能问答平台，实现内部知识的快速检索、精准问答与高效传递。

技术栈：Python、LangChain、Qwen-14B、BGE-M3、BGE-Rerank-large、Redis、Milvus、BERT

项目职责：

1. 构建RAG知识库，整理并清洗PDF/Word等文档资料，累计构建 30万+条数据
2. 搭建 Milvus 向量数据库，设计多集合存储策略，支持制度、流程、业务知识、技术文档等不同类型知识的隔离管理与高效检索；

3. RAG核心模块开发: 通过BGE-M3模型生成稠密向量和稀疏向量, 实现混合检索。引入Cross-Encoder模型进行重排序, 提高检索精确度。
4. 大模型接口集成与优化: 对接模型, 封装调用逻辑, 实现“检索结果+用户问题”的Prompt构造, 优化Prompt模板提升回答准确性。
5. 使用 RagAS 自动评估框架对RAG全流程进行量化评测

项目成果:

1. 提升知识检索效率: 系统上线后, 员工获取内部知识的平均时间从20分钟缩短至秒级, 检索效率提升95%以上; 支持自然语言提问, 无需记忆文档路径或关键词, 大幅降低了知识获取门槛。
2. 使用RagAS评估忠实度达到91%, 答案相关性达到88%,
3. 技术成果落地: 形成可复用的RAG架构企业内部问答解决方案, 封装了文档解析、向量生成、等通用模块, 可快速适配企业后续新增的知识场景 (如客户资料管理)。

2024.08-2025.04

售后智能助理系统

项目背景:

企业面临客服团队人力成本高、响应效率低、服务标准化不足的核心痛点, 人工客服易受情绪、专业度影响, 服务话术不统一, 易出现解答偏差, 导致客户满意度偏低; 同时, 售后问题多为高频重复类 (占比超70%), 人工反复处理此类问题, 效率低下且浪费人力成本, 制约企业客户留存与品牌口碑提升。为解决上述痛点, 提升客户服务质量, 特启动客服/售后智能助理项目, 依托大模型技术, 构建一款轻量化、易部署、低成本的智能助理, 替代人工处理高频重复客服咨询。

技术栈:

Qwen-14B、LoRA、MCP、FastAPI、MySQL、Redis、Milvus、BGE-M3、ES

项目职责:

1. 需求梳理: 参与项目需求梳理, 跟业务对齐需求, 生成需求文档。
2. 模型微调: 基于PEFT (LoRA/QLoRA) 方法, 实现模型轻量化微调, 利用企业少量业务数据, 适配企业具体客服场景。
3. 核心算法开发优化: 开发意图识别模块, 调试迭代算法, 确保模型精准理解客户意图, 提升响应速度与回复准确率。
4. 数据标注与模型评估: 参与业务数据标注规划, 设计模型评估指标, 定期开展评估, 针对问题迭代优化模型与算法。

项目成果:

1. 效率提升: 智能助手承接70%以上的常规售后咨询, 平均响应时间从150秒缩短至25秒, 客服人均接待量提升120%, 解决了高峰期客服排队拥堵问题。
2. 成本降低: 通过智能助手替代部分人工客服工作, 优化客服团队结构, 节省人力成本; 新员工培训周期从3个月缩短至1个月, 培训成本降低40%。
3. 准确性保障: 外部大模型结合RAG检索技术, 回答准确率从传统关键词检索的65%提升至92%。

4. 知识库优化：建立标准化的知识库维护体系，实现知识库实时更新、批量管理，累计完成 800+份文档的结构化处理，检索覆盖率提升至98%，避免因知识库更新不及时导致的回答偏差。

2024.02-2024.07

学科题型知识点分类项目

项目背景：

在线小学教育平台每月接收学生上传的作业错题文本超 8 万条。平台需通过分类将错题精准匹配至“知识点模块”，然后存入数据库做但当前存在一个核心问题：就是人工标注效率极低，加班成本极高。本项目通过对bert预训练模型进行全量参数微调，训练出具有高准确率分类能力的模型工具，减少人力成本。

技术栈：

随机森林、Fasttext、bert、pytorch、知识蒸馏、fine-tuning

项目职责：

1. 数据预处理：采集历史 1 年错题文本数据共 96 万条（含教研团队标注的知识点标签），按 8:1:1 划分为训练集、验证集、测试集。用 jieba 分词处理题干与错误解答文本，剔除“请作答”“错误：”等无关表述，保留“知识点关键词”。进行标签均衡性分析和文本长度分析，最后确定标准长度为300。
2. 模型搭建与训练：使用随机森林作为基线模型来对数据可行性进行基本验证，知识点分类的准确率达到60.4%，将其作后续训练时的性能参考。使用chinese-bert-wwm-ext预训练模型+全参微调构建具有强分类能力的模型：模型架构上，在 BERT 输出层添加 30 分类全连接层并且使用sigmoid激活函数，训练过程中采用全量微调的方式；设置批次大小 64，学习率 1e-5，用二元交叉熵损失函数BCEWithLogitsLoss，使用Adamw优化器训练 40 轮，对测试集样本进行预测，知识点分类准确率提升至 96.1%。
3. 模型优化：对Bert模型进行量化，模型体积从 420MB 压缩至 30MB（压缩 92.8%），推理速度从单条 0.18 秒提升至 0.06 秒（提升 200%），知识点分类准确率下降 7.8%（88.3%），不符合准确率90%以上的要求。使用较少层的编码器架构作为学生模型与训练后的Bert模型进行知识蒸馏，模型体积从 420MB 压缩至 140MB（压缩 66.7%），推理速度从单条 0.18 秒提升至 0.06 秒（提升 200%），知识点分类准确率仅下降 0.9%（95.2%），完全满足实时反馈需求和准确率要求。

项目成果：

优化后的轻量化 Bert 模型（140MB）成功部署至在线教育平台核心业务链路，支持日均 10 万 + 条学生错题文本的实时分类请求，节省相关人力成本约 70%。